

修士論文

バードストライク検出に向けた
コンピュータビジョンと
UAV の活用

山形大学大学院
理工学研究科数理科学分野
23321427 千葉歩夢

2025 年 2 月

Abstract

ここに概要を書きます。

Contents

0.1	はじめに	2
0.1.1	背景と目的	2
0.1.2	先行研究の概要	2
0.1.3	引き継ぎの理由	2
0.1.4	本研究の目的	2
0.2	方法とアルゴリズム	3
0.2.1	科学用語の説明	3
0.2.2	AutoEncoder の改良	4

0.1 はじめに

0.1.1 背景と目的

近年、再生可能エネルギーの 1 つである風力発電の導入が注目されているが、発電機の建設には問題点も多い。バードストライクはその問題点の 1 つであり、回転する風車のブレードに鳥類が衝突する現象である。山形県企業局では、当局が管理している風力発電機に対してバードストライク調査を行っているが、仕事量の多さや正確性に幅があることが懸念されている。この懸念を解消するために、ドローンを用いて発電機周辺の土地を撮影し、自動的に鳥の死骸を発見できるプログラムを作成することが本研究の目的である。

詳しい内容は昨年度の論文で詳細に説明しているので、そちらを参照して欲しい。

0.1.2 先行研究の概要

昨年度、山形大学の先輩である梅津魁秀氏は、深層学習を用いたバードストライク調査プログラムの基礎的な研究を行った。彼の研究では、AutoEncoder を用いて物体検出モデルを作成し、ドローン画像から鳥の死骸を検出する手法を提案した。具体的には、ドローン画像を「物体が存在する画像」と「物体が存在しない画像」に分類し、さらに「物体が存在する画像」を「鳥の死骸の画像」と「鳥の死骸ではない画像」に分類する手法を開発した。また、物体と鳥の区別を手動で行うための GUI も開発した。彼の研究により、物体画像に関して F2-score が 0.83 という高い精度で物体の有無を判定することができた。

0.1.3 引き継ぎの理由

梅津氏の研究は有望な結果を示したが、実用化にはさらなる改良が必要である。特に、検出精度の向上とリアルタイム処理の実現が課題として残されている。これらの課題を解決するために、本研究では梅津氏の研究を引き継ぎ、さらなる改良を行う。

0.1.4 本研究の目的

本研究の目的は、梅津氏の研究を基にして、バードストライク検出システムの精度向上とリアルタイム処理の実現を目指すことである。具体的には、UAV を用いたデータ収集と、機械学習アルゴリズムの適用による検出精度の向上を図る。また、調査担当者が確認する画像枚数を削減し、省力化や時間削減を実現することを目指す。

0.2 方法とアルゴリズム

ここからはバードストライク調査プログラムの作成に使用する方法やアルゴリズムを紹介する。なお、今年度は引継ぎのため、重複する部分は省略し、新規の内容や変更した内容のみ説明する。

0.2.1 科学用語の説明

本研究では、風力発電所におけるバードストライク調査を自動化するために、さまざまな技術を使用している。以下に、研究の中で使用される主要な科学用語を説明する。

AutoEncoder (オートエンコーダ)

AutoEncoder は、入力データを圧縮し、その圧縮されたデータから元のデータを再構築することを目的としたニューラルネットワークの一種である。主にデータの次元削減や特徴抽出に使用される。AutoEncoder はエンコーダとデコーダの 2 つの部分から構成され、エンコーダは入力データを低次元の潜在空間にマッピングし、デコーダはその潜在空間から元のデータを再構築する。

CLIP (Contrastive Language-Image Pre-Training)

CLIP は、OpenAI によって開発されたモデルで、画像とテキストのペアを用いて学習することで、画像とテキストの間の関連性を高精度で捉えることができる。CLIP は、画像エンコーダとテキストエンコーダを用いて、それぞれの入力を高次元のベクトルに変換し、これらのベクトル間のコサイン類似度を最大化するように学習する。これにより、画像とテキストの間の関連性を高精度で捉えることができる。

ResNet (Residual Networks)

ResNet は、深層ニューラルネットワークの一種であり、深いネットワークにおける勾配消失問題を解決するために開発された。ResNet は、残差ブロックを導入することで、非常に深いネットワークでも効果的に学習を行うことができる。これにより、画像認識の精度が大幅に向上することが示されている [3]。

RN50 および **RN50x64**

RN50 は、ResNet-50 をベースとしたモデルであり、50 層の深層ニューラルネットワークを用いて画像をエンコードする。RN50x64 は、ResNet-50

を 64 倍に拡張したモデルであり、より高精度な画像特徴量を抽出することができる。これらのモデルは、CLIP の画像エンコーダとして機能し、テキストエンコーダと組み合わせることで、画像とテキストの関連性を高精度で捉えることができる。

主成分分析 (Principal Component Analysis, PCA)

主成分分析は、高次元データを低次元に変換するための統計手法である。データの分散を最大化する方向に新しい軸（主成分）を見つけ、その軸にデータを投影することで次元削減を行う。これにより、データの重要な特徴を保持しつつ、次元を削減することができる。

K-means クラスタリング

K-means クラスタリングは、データを K 個のクラスタに分割するための非階層型クラスタリング手法である。各クラスタは、クラスタの中心（重心）からの距離が最小になるようにデータポイントを割り当てることで形成される。K-means クラスタリングは、データのパターンを見つけるために広く使用される。

コサイン類似度

コサイン類似度は、2 つのベクトル間の類似度を測るための指標である。ベクトル間の角度のコサイン値を計算することで、ベクトルの方向がどれだけ似ているかを評価する。コサイン類似度は、0 から 1 の範囲で値を取り、1 に近いほどベクトルが類似していることを示す。

0.2.2 AutoEncoder の改良

本研究では、以前の AutoEncoder モデルと比較して、構造をシンプルにすることで性能向上を図った。以下に、以前のモデルと現在のモデルの違い、およびその違いによる良い変化について説明する。

以前の AutoEncoder モデル

以前の AutoEncoder モデルは、以下のような構造を持っていた。

現在の AutoEncoder モデル

現在の AutoEncoder モデルは、以前のモデルと比較して構造がシンプルになっている。具体的には、以下のような変更が加えられた。

- 畳み込み層と逆畳み込み層の数を減らし、モデルの深さを浅くした。
- バッチ正規化層を削除し、計算コストを削減した。
- ReLU 活性化関数の使用を最小限に抑えた。

改良の効果

これらの変更により、以下のような良い変化が見られた。

- 計算コストの削減: モデルの深さを浅くし、バッチ正規化層を削除することで、計算コストが大幅に削減された。これにより、学習速度が向上し、より短時間でモデルのトレーニングが完了するようになった。
- 過学習の防止: モデルのパラメータ数を減らすことで、過学習のリスクが低減された。これにより、テストデータに対する汎化性能が向上し、より安定した結果が得られるようになった。
- モデルの解釈性の向上: 構造をシンプルにすることで、モデルの挙動がより理解しやすくなった。これにより、モデルの改善点や問題点を特定しやすくなり、さらなる改良が容易になった。

以上のように、現在の AutoEncoder モデルは、以前のモデルと比較して構造がシンプルになり、計算コストの削減、過学習の防止、モデルの解釈性の向上といった良い変化が見られた。

AutoEncoder モデルのアップデートの重要性

AutoEncoder モデルをアップデートすることは、モデルの性能向上や新しいデータへの適応において非常に重要だ。以下に、モデルをアップデートしないで使い続けることと、アップデートして使うことの差について説明する。

モデルをアップデートしない場合 モデルをアップデートしないで使い続けると、以下のような問題が発生する可能性がある。

- 性能の劣化: 新しいデータや環境に適応できず、モデルの性能が徐々に劣化する可能性がある。例えば、[2] では、モデルの性能がデータの変化に対して敏感であることが示されている。
- 過学習: 古いデータに対して過学習してしまい、新しいデータに対して一般化能力が低下する可能性がある。過学習は、モデルの汎化性能を低下させる主要な要因の一つだ [1]。

モデルをアップデートする場合 一方、モデルを定期的にアップデートすることで、以下のような利点がある。

- 性能向上: 新しいデータや技術を取り入れることで、モデルの性能を向上させることができる。例えば、[3] では、ResNet のような新しいアーキテクチャを導入することで、画像認識の精度が大幅に向上したことが示されている。
- 適応能力の向上: モデルが新しいデータや環境に適応できるようになり、汎化性能が向上する。これは、モデルがより広範なデータセットに対して有効であることを意味する [4]。

結論 以上のように、AutoEncoder モデルをアップデートすることは、性能向上、適応能力の向上など、多くの利点がある。したがって、モデルを定期的にアップデートすることは、長期的な視点で見ても非常に重要だ。




Figure 1: 以前の AutoEncoder の構造

(入力チャンネル, 出力チャンネル)




Figure 2: 現在の AutoEncoder の構造

(入力チャンネル, 出力チャンネル)

Bibliography

- [1] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [4] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436–444, 2015.